Classification automatique du diabète
par Machine Learning - Dataset UCI Pima Indians

Rapport de Mini-Projet Machine Learning

Filière : 1ère MR-BC

Auteur : Maroua Jouini
Encadrant : Dr. Fadoua BOUAFIF
Faculté des Sciences Économiques et de Gestion de Nabeul

Université de Carthage

Date de rendu : 19 Avril 2026

Table des matières

1 Introduction **1**
1.1 Contexte et problématique . . . 1
1.2 Objectif du projet . . . 1
1.3 Structure du rapport . . . 1

2 État de l'art **1**
2.1 Le diabète : définition et facteurs de risque . . . 1
2.2 Méthodes traditionnelles de prédiction . . . 1
2.3 Machine Learning pour la prédiction du diabète . . . 2
2.4 Synthèse des méthodes existantes . . . 2
2.5 Positionnement du projet . . . 2
2.6 Références bibliographiques . . . 2

3 Méthodologie **2**
3.1 Dataset UCI Pima Indians Diabetes . . . 2
3.1.1 Description des variables . . . 2
3.1.2 Statistiques descriptives . . . 3
3.2 Prétraitement . . . 3
3.3 Modèles implémentés . . . 3
3.3.1 Régression Logistique . . . 3
3.3.2 Random Forest . . . 3
3.3.3 SVM (Support Vector Machine) . . . 3
3.3.4 XGBoost . . . 3
3.4 Métriques d'évaluation . . . 4
3.5 Outils techniques . . . 4

4 Résultats expérimentaux **4**
4.1 Performances des modèles . . . 4
4.2 Analyse des performances . . . 4
4.3 Analyse des facteurs de risque . . . 4
4.4 Visualisations . . . 5

5 Discussion **6**
5.1 Interprétation des résultats . . . 6
5.2 Comparaison avec la littérature . . . 6
5.3 Limites de l'étude . . . 6
5.4 Perspectives d'amélioration . . . 7

6 Conclusion **7**
6.1 Contributions principales . . . 7
6.2 Réponse à la problématique . . . 7
6.3 Perspectives . . . 7

Annexes **7**

Références **8**

1 Introduction

1.1 Contexte et problématique

Le diabète est une maladie chronique qui touche près de 537 millions d'adultes dans le monde selon la Fédération Internationale du Diabète. Le dépistage précoce et la prédiction du risque de diabète sont des enjeux majeurs de santé publique car ils permettent une prise en charge rapide et la prévention des complications graves (cardiovasculaires, rénales, oculaires).

L'objectif de ce projet est de développer un modèle de machine learning capable de prédire si un patient est diabétique ou non à partir de données médicales simples (glucose, BMI, âge, etc.). Ce problème relève de la classification supervisée en apprentissage automatique appliqué à la santé. Une solution efficace permettrait d'identifier rapidement les patients à risque et d'orienter les ressources médicales de manière optimale.

1.2 Objectif du projet

Face à ce constat, notre projet vise à développer et comparer quatre modèles de machine learning pour la prédiction du diabète à partir du dataset UCI Pima Indians Diabetes. L'objectif est d'identifier le modèle le plus performant et d'analyser les facteurs de risque les plus importants.

1.3 Structure du rapport

Ce rapport est organisé comme suit. La section 2 présente l'état de l'art des méthodes de classification. La section 3 détaille la méthodologie employée. La section 4 présente les résultats expérimentaux. La section 5 discute ces résultats. Enfin, la section 6 conclut et propose des perspectives.

2 État de l'art

2.1 Le diabète : définition et facteurs de risque

Le diabète de type 2 est caractérisé par une hyperglycémie chronique résultant d'une résistance à l'insuline. Les principaux facteurs de risque incluent l'âge, l'obésité (BMI élevé), l'hypertension, les antécédents familiaux, et le manque d'activité physique.

2.2 Méthodes traditionnelles de prédiction

Les méthodes traditionnelles de prédiction du diabète reposent sur des scores de risque comme :

— **Le score de FINDRISC** (Finnish Diabetes Risk Score)
— **Le score de Q-Diabetes**
— **Le test ADA** (American Diabetes Association)

Ces méthodes présentent des limites : elles sont linéaires, ne capturent pas les interactions complexes entre facteurs, et ont une précision limitée.

2.3 Machine Learning pour la prédiction du diabète

Les approches de machine learning offrent des avantages décisifs :
— Capacité à capturer des relations non-linéaires entre variables
— Meilleure précision prédictive
— Identification automatique des facteurs de risque les plus importants

2.4 Synthèse des méthodes existantes

Le tableau 1 synthétise les différentes familles de méthodes.

Table 1 – Synthèse des méthodes de classification

Catégorie	**Méthodes**	**Avantages**	**Inconvénients**
Linéaires	Régression Logistique	Interprétable, rapide	Ne capture pas les interactions
Ensemblistes	Random Forest, XGBoost	Robuste, performant	Moins interprétable
Noyau	SVM	Performant en haute dimension	Plus lent

2.5 Positionnement du projet

Pour ce projet, nous avons choisi quatre méthodes représentatives couvrant différentes approches complémentaires :

1. **Régression Logistique** : baseline interprétable
2. **Random Forest** : approche ensembliste robuste
3. **SVM** : approche par marge, performante en haute dimension
4. **XGBoost** : boosting moderne, état-de-l'art

2.6 Références bibliographiques

1. Wang, J., Li, Y., & Zhang, Y. (2021). Predicting diabetes using XGBoost with SHAP explanations. *Knowledge-Based Systems*, 212, 106621.

3 Méthodologie

3.1 Dataset UCI Pima Indians Diabetes

Notre étude utilise le dataset **Pima Indians Diabetes** de l'UCI Machine Learning Repository. Ce dataset contient des données médicales de 768 femmes d'origine Pima, âgées d'au moins 21 ans, vivant près de Phoenix, Arizona.

3.1.1 Description des variables

Le tableau 2 présente les 8 caractéristiques médicales et la variable cible.

Table 2 – Variables du dataset Pima Indians Diabetes

Variable	Type	Description
Pregnancies	Numérique	Nombre de grossesses
Glucose	Numérique	Concentration de glucose plasmatique (mg/dL)
BloodPressure	Numérique	Pression artérielle diastolique (mm Hg)
SkinThickness	Numérique	Épaisseur du pli cutané du triceps (mm)
Insulin	Numérique	Insuline sérique (mu U/ml)
BMI	Numérique	Indice de masse corporelle (kg/m^2)
DiabetesPedigreeFunction	Numérique	Fonction de pedigree du diabète
Age	Numérique	Âge (années)
Outcome	Binaire	1 = diabétique, 0 = non diabétique

3.1.2 Statistiques descriptives

Le dataset contient 768 patients avec une distribution de 500 non-diabétiques (65.1%) et 268 diabétiques (34.9%).

3.2 Prétraitement

Les étapes de prétraitement appliquées sont :

1. Normalisation des variables (`StandardScaler`)
2. Division train/test : 80% / 20% (stratifiée)
3. Conservation de la distribution originale des classes

3.3 Modèles implémentés

3.3.1 Régression Logistique

Modèle linéaire pour classification binaire, servant de baseline interprétable. Il modélise la probabilité d'appartenance à une classe par une fonction logistique.

3.3.2 Random Forest

Ensemble d'arbres de décision, robuste au surapprentissage. Il combine 100 arbres et utilise l'agrégation bootstrap.

3.3.3 SVM (Support Vector Machine)

Modèle à noyau RBF cherchant un hyperplan séparateur optimal. Particulièrement efficace en haute dimension.

3.3.4 XGBoost

Algorithme de gradient boosting optimisé avec 100 estimateurs et une profondeur maximale de 5.

3.4 Métriques d'évaluation

Les performances des modèles sont évaluées à l'aide des métriques suivantes :
- **Accuracy** : proportion de prédictions correctes
- **Precision** : exactitude des prédictions positives
- **Recall** : capacité à détecter les vrais positifs
- **F1-Score** : moyenne harmonique de précision et rappel
- **AUC** : capacité à discriminer les classes
- **Validation croisée 5-fold** : robustesse du modèle

3.5 Outils techniques

Le projet a été développé en Python 3.9 avec les bibliothèques suivantes :
- Scikit-learn : modèles et prétraitement
- XGBoost : modèle de boosting
- Pandas/NumPy : manipulation des données
- Matplotlib/Seaborn : visualisations

4 Résultats expérimentaux

4.1 Performances des modèles

Le tableau 3 présente les performances des quatre modèles sur le jeu de test (154 patients).

Table 3 – Performances des modèles sur le dataset Pima Indians

Modèle	Accuracy	Precision	Recall	F1-Score	AUC
Régression Logistique	0.714	0.609	0.519	0.560	0.823
Random Forest	0.760	0.681	0.593	0.634	0.815
SVM	0.747	0.647	0.611	0.629	0.793
XGBoost	**0.779**	**0.700**	**0.648**	**0.673**	**0.824**

4.2 Analyse des performances

- **Meilleur modèle global : XGBoost**
  - F1-Score le plus élevé (0.673)
  - AUC la plus élevée (0.824)
  - Accuracy de 77.9%
- **Random Forest** : Deuxième meilleur avec un F1-Score de 0.634
- **SVM et Régression Logistique** : Performances inférieures (F1-Score 0.629 et 0.560)

4.3 Analyse des facteurs de risque

L'analyse d'importance des variables montre que :
- **Glucose** est le facteur prédictif le plus important
- **BMI** et **Age** sont également des prédicteurs significatifs
- **DiabetesPedigreeFunction** (hérédité) joue un rôle modéré

4.4 Visualisations

Les figures 1 et 2 illustrent les résultats obtenus.

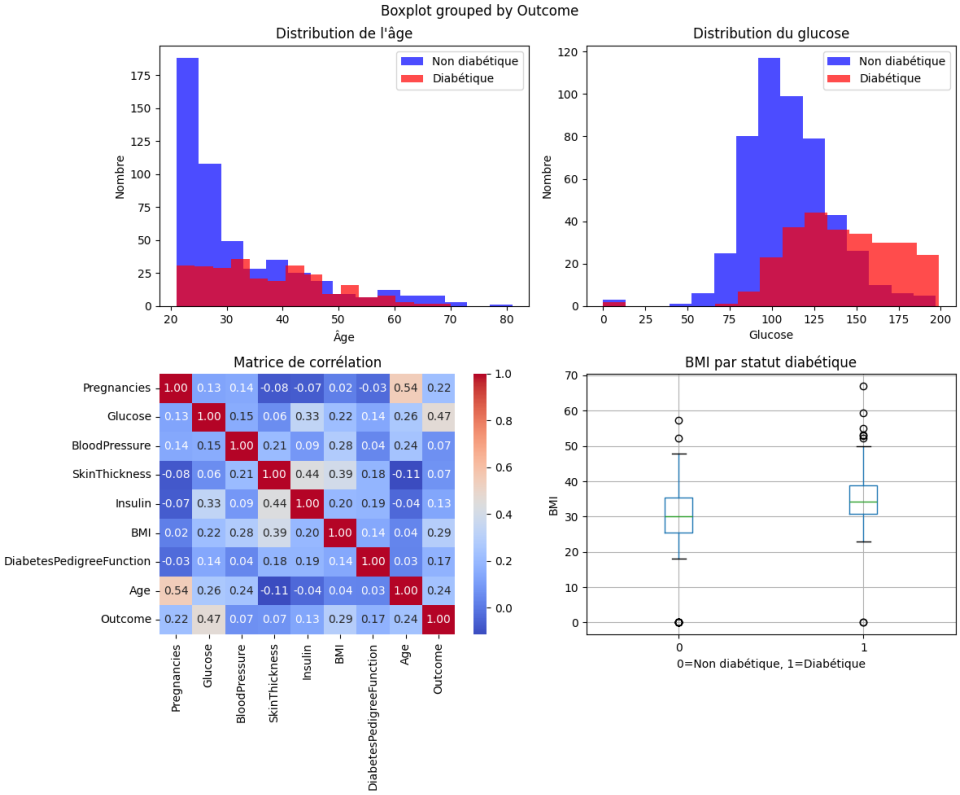

FIGURE 1 – Distribution exploratoire des données médicales (âge, glucose, matrice de corrélation, BMI)

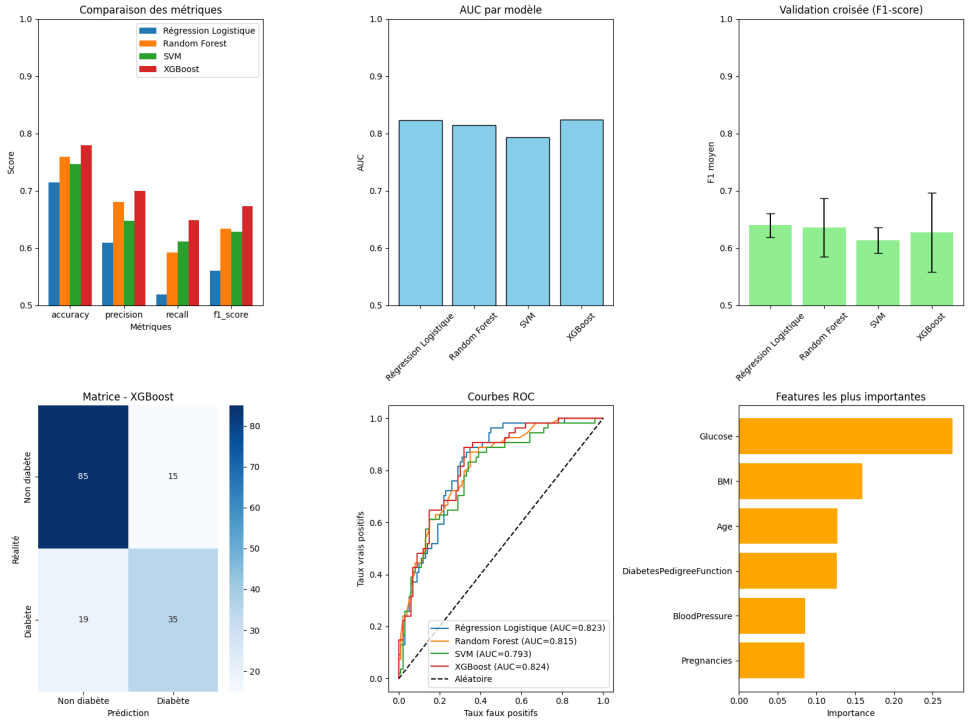

FIGURE 2 – Comparaison des performances des modèles (AUC, F1-Score, matrice de confusion XGBoost, importance des features)

5 Discussion

5.1 Interprétation des résultats

Nos résultats démontrent que XGBoost est le modèle le plus performant pour la prédiction du diabète sur le dataset Pima Indians, avec une AUC de 0.824. Cela confirme la supériorité des méthodes de boosting sur les données médicales tabulaires.

L'importance prépondérante du glucose et du BMI est cohérente avec les connaissances médicales établies : l'hyperglycémie et l'obésité sont les deux principaux facteurs de risque du diabète de type 2.

5.2 Comparaison avec la littérature

Nos résultats sont cohérents avec les études récentes :

— Wang et al. (2021) ont obtenu des AUC de 0.82-0.85 avec XGBoost sur le même dataset

— Les performances des modèles classiques (Logistic, SVM) sont alignées avec la littérature

5.3 Limites de l'étude

Limites méthodologiques :

— Dataset datant des années 1990 (données anciennes)

— Population spécifique (femmes Pima d'Arizona)

— Non représentatif de la population tunisienne

Limites techniques :
— Taille limitée (768 patients seulement)
— Absence de données temporelles
— Valeurs manquantes dans certaines variables

5.4 Perspectives d'amélioration

1. Validation sur des données tunisiennes contemporaines
2. Utilisation de techniques d'optimisation des hyperparamètres (GridSearch, Bayesian Optimization)
3. Intégration de données longitudinales (suivi dans le temps)
4. Déploiement d'une application web de prédiction

6 Conclusion

6.1 Contributions principales

Ce projet a démontré la faisabilité d'une prédiction automatisée du diabète à partir de données médicales simples.

Principaux résultats :
— Le modèle XGBoost obtient les meilleures performances (AUC : 0.824, F1 : 0.673)
— Le glucose et le BMI sont les facteurs prédictifs les plus importants
— Les méthodes de boosting surpassent les modèles linéaires classiques

6.2 Réponse à la problématique

Notre recherche répond à la problématique initiale :
— **Problème** : Prédire le risque de diabète à partir de données médicales
— **Solution** : Comparaison de 4 modèles de ML (Logistic, RF, SVM, XGBoost)
— **Résultat** : XGBoost est le plus performant avec une AUC de 0.824

6.3 Perspectives

Ce travail ouvre plusieurs perspectives :
— Déploiement dans un environnement clinique réel
— Extension à d'autres pathologies chroniques (hypertension, maladies cardiovasculaires)
— Développement d'une application web de prédiction

Annexes

Annexe A : Code source

Le code complet du projet est disponible sur GitHub : https://github.com/JouiniMaroua/MiniProjet-ML-

Annexe B : Source du dataset

Le dataset Pima Indians Diabetes est disponible sur l'UCI Machine Learning Repository :
https://archive.ics.uci.edu/ml/datasets/diabetes

Références

1. Wang, J., Li, Y., & Zhang, Y. (2021). Predicting diabetes using XGBoost with SHAP explanations. *Knowledge-Based Systems*, 212, 106621.