Prédiction de la non-adhérence au traitement

chez les patients diabétiques de type 2

Rapport de Mini-Projet Machine Learning

Filière : 1ère MR-BC

Auteur : Maroua Jouini
Encadrant : Dr. Fadoua BOUAFIF
Faculté des Sciences Économiques et de Gestion de Nabeul

Université de Carthage

Date de rendu : 19 Avril 2026

Table des matières

1 Introduction **1**
- 1.1 Contexte et problématique . . . 1
- 1.2 Objectif du projet . . . 1
- 1.3 Structure du rapport . . . 1

2 État de l'art **1**
- 2.1 L'adhérence médicamenteuse : définition et enjeux . . . 1
- 2.2 Méthodes traditionnelles d'évaluation . . . 1
- 2.3 Machine Learning pour la prédiction d'adhérence . . . 2
- 2.4 Synthèse des méthodes existantes . . . 2
- 2.5 Positionnement du projet . . . 2
- 2.6 Références bibliographiques . . . 2

3 Méthodologie **3**
- 3.1 Dataset . . . 3
- 3.2 Prétraitement . . . 3
- 3.3 Modèles implémentés . . . 3
  - 3.3.1 Régression Logistique . . . 3
  - 3.3.2 Random Forest . . . 3
  - 3.3.3 SVM (Support Vector Machine) . . . 3
  - 3.3.4 XGBoost . . . 3
- 3.4 Métriques d'évaluation . . . 3
- 3.5 Outils techniques . . . 4

4 Résultats expérimentaux **4**
- 4.1 Performances des modèles . . . 4
- 4.2 Analyse des performances . . . 4
- 4.3 Analyse par quartiles de risque . . . 4
- 4.4 Impact clinique . . . 5
- 4.5 Visualisations . . . 5

5 Discussion **6**
- 5.1 Interprétation des résultats . . . 6
- 5.2 Comparaison avec la littérature . . . 7
- 5.3 Limites de l'étude . . . 7
- 5.4 Perspectives d'amélioration . . . 7

6 Conclusion **7**
- 6.1 Contributions principales . . . 7
- 6.2 Réponse à la problématique . . . 7
- 6.3 Perspectives . . . 8

Annexes **8**

Références **8**

1 Introduction

1.1 Contexte et problématique

L'adhésion au traitement médicamenteux représente un défi majeur dans la prise en charge des maladies chroniques, en particulier le diabète de type 2. Selon l'Organisation Mondiale de la Santé, environ 50% des patients atteints de maladies chroniques n'adhèrent pas correctement à leurs traitements prescrits. Dans le contexte spécifique du diabète, les études rapportent des taux de non-adhérence variant de 41,5% à 76,9% selon les populations.

Cette non-adhérence a des conséquences graves :

- Mauvais contrôle glycémique (HbA1c élevée)
- Augmentation des complications (rétinopathie, néphropathie, neuropathie)
- Hospitalisations évitables
- Hausse significative des coûts de santé
- Diminution de la qualité de vie des patients

1.2 Objectif du projet

Face à ce constat, notre projet vise à développer un modèle de machine learning capable de prédire, à partir de données médico-sociales accessibles, quels patients diabétiques sont à risque élevé de non-adhérence à leur traitement. L'objectif est de fournir aux professionnels de santé un outil d'alerte précoce leur permettant d'intervenir de manière ciblée auprès des patients les plus vulnérables. Ce problème relève de la classification supervisée en apprentissage automatique appliqué à la santé.

1.3 Structure du rapport

Ce rapport est organisé comme suit. La section 2 présente l'état de l'art des méthodes de prédiction d'adhérence médicamenteuse. La section 3 détaille la méthodologie employée. La section 4 présente les résultats expérimentaux. La section 5 discute ces résultats. Enfin, la section 6 conclut et propose des perspectives.

2 État de l'art

2.1 L'adhérence médicamenteuse : définition et enjeux

L'adhérence médicamenteuse se définit comme le degré de conformité du patient aux recommandations thérapeutiques prescrites par son médecin. Les causes de non-adhérence sont multifactorielles : facteurs socio-économiques, complexité du régime médicamenteux, effets secondaires, oubli, manque de compréhension, barrières culturelles.

2.2 Méthodes traditionnelles d'évaluation

Avant l'avènement du machine learning, l'évaluation de l'adhérence reposait sur :

- **L'auto-questionnaire** (GMAS, MMAS-8) : simple mais sujet aux biais de désirabilité sociale
- **Le comptage de pilules** : fastidieux et peu fiable

— **Les données de renouvellement d'ordonnance** : indicateur objectif mais limité
— **Les dispositifs électroniques** : coûteux

Ces méthodes présentent des limites majeures : elles sont statiques, ne capturent pas les interactions complexes entre facteurs, et ne permettent pas une prédiction précoce du risque.

2.3 Machine Learning pour la prédiction d'adhérence

Les approches de machine learning offrent des avantages décisifs :
— Capacité à capturer des relations non-linéaires entre variables
— Réduction des biais par apprentissage automatique
— Flexibilité dans la prévention du surapprentissage

2.4 Synthèse des méthodes existantes

Le tableau 1 synthétise les différentes familles de méthodes.

Table 1 – Synthèse des méthodes de classification

Catégorie	**Méthodes**	**Avantages**	**Inconvénients**
Linéaires	Régression Logistique	Interprétable, rapide	Ne capture pas les interactions
Ensemblistes	Random Forest, XGBoost	Robuste, performant	Moins interprétable
Noyau	SVM	Performant en haute dimension	Plus lent

2.5 Positionnement du projet

Pour ce projet, nous avons choisi quatre méthodes représentatives couvrant différentes approches complémentaires :

1. **Régression Logistique** : baseline interprétable, permet de comprendre les facteurs clés
2. **Random Forest** : approche ensembliste robuste, excellente sur données tabulaires
3. **SVM** : approche par marge, performante en haute dimension
4. **XGBoost** : boosting moderne, état-de-l'art sur ce type de problème

2.6 Références bibliographiques

1. Kassaw, E. A., et al. (2025). Machine learning applications to classify and monitor medication adherence in patients with type 2 diabetes in Ethiopia. *Frontiers in Endocrinology*, 16, 1486350.
2. Zhang, J., & Qu, J. Z. (2025). Assessment of Medication Adherence in Patients : Development and Validation of a Machine Learning Model. *medRxiv*.
3. World Health Organization. (2003). *Adherence to long-term therapies : evidence for action*. WHO Press.

3 Méthodologie

3.1 Dataset

Notre étude utilise un dataset de 1000 patients simulés basé sur les caractéristiques identifiées dans la littérature scientifique. Les données incluent 15 caractéristiques réparties en trois catégories :

— **Caractéristiques démographiques** : âge, sexe, niveau d'éducation, niveau de revenu

— **Caractéristiques cliniques** : durée du diabète, HbA1c, nombre de complications

— **Caractéristiques comportementales** : visites à la pharmacie, retards de renouvellement, score d'oubli, effets secondaires, nombre de médicaments, assurance, distance à la pharmacie, soutien social

La variable cible est binaire : adhérent (0) vs non-adhérent (1). La distribution initiale montre 13.4% de patients non-adhérents.

3.2 Prétraitement

Les étapes de prétraitement appliquées sont :

1. Normalisation des variables (`StandardScaler`)
2. Division train/test : 80% / 20% (stratifiée)
3. Application de SMOTE pour équilibrer les classes

3.3 Modèles implémentés

3.3.1 Régression Logistique

Modèle linéaire pour classification binaire, servant de baseline interprétable. Il modélise la probabilité d'appartenance à une classe par une fonction logistique.

3.3.2 Random Forest

Ensemble d'arbres de décision, robuste au surapprentissage. Il combine 100 arbres et utilise l'agrégation bootstrap.

3.3.3 SVM (Support Vector Machine)

Modèle à noyau RBF cherchant un hyperplan séparateur optimal. Particulièrement efficace en haute dimension.

3.3.4 XGBoost

Algorithme de gradient boosting optimisé avec 100 estimateurs et une profondeur maximale de 5.

3.4 Métriques d'évaluation

Les performances des modèles sont évaluées à l'aide des métriques suivantes :

— **Accuracy** : proportion de prédictions correctes

— **Precision** : exactitude des prédictions positives
— **Recall** : capacité à détecter les vrais positifs
— **F1-Score** : moyenne harmonique de précision et rappel
— **AUC** : capacité à discriminer les classes
— **Validation croisée 5-fold** : robustesse du modèle

3.5 Outils techniques

Le projet a été développé en Python 3.9 avec les bibliothèques suivantes :
— Scikit-learn : modèles et prétraitement
— XGBoost : modèle de boosting
— Imbalanced-learn : SMOTE pour rééquilibrage
— Pandas/NumPy : manipulation des données
— Matplotlib/Seaborn : visualisations

4 Résultats expérimentaux

4.1 Performances des modèles

Le tableau 2 présente les performances des quatre modèles sur le jeu de test (200 patients).

Table 2 – Performances des modèles

Modèle	Accuracy	Precision	Recall	F1-Score	AUC
Régression Logistique	0.840	0.442	0.704	0.543	0.905
Random Forest	0.900	0.706	0.444	0.545	0.914
SVM	**0.885**	0.567	0.630	**0.596**	0.913
XGBoost	0.900	0.667	0.519	0.583	**0.917**

4.2 Analyse des performances

— **Meilleur modèle global : SVM**
  — F1-Score le plus élevé (0.596)
  — Bon équilibre entre précision (56.7%) et rappel (63.0%)
  — AUC excellente (0.913)
— **Meilleure discrimination : XGBoost**
  — AUC la plus élevée (0.917)
  — Capacité supérieure à distinguer adhérents et non-adhérents
— **Observation importante :** La Régression Logistique a le meilleur rappel (70.4%), détectant correctement 70% des patients non-adhérents, mais sa précision plus faible (44.2%) génère davantage de faux positifs.

4.3 Analyse par quartiles de risque

Les patients ont été divisés en quartiles selon leur score de risque prédit par le meilleur modèle. Le tableau 3 présente les résultats.

TABLE 3 – Analyse par quartiles de risque

Quartile	Taux de non-adhérence	HbA1c moyenne
Q1 (Faible)	0.0%	7.1%
Q2 (Modéré)	0.4%	7.3%
Q3 (Élevé)	1.2%	7.8%
Q4 (Très élevé)	**52.0%**	7.7%

4.4 Impact clinique

Les résultats montrent un impact clinique significatif :

— Les patients du quartile "très haut risque" ont une probabilité de non-adhérence de **52%**, soit 50 fois plus élevée que celle des patients des quartiles inférieurs.

— L'HbA1c moyenne des patients à haut risque (7.7%) dépasse le seuil recommandé de 7%, confirmant l'impact négatif de la non-adhérence sur le contrôle glycémique.

4.5 Visualisations

Les figures 1, 2 et 3 illustrent les résultats obtenus.

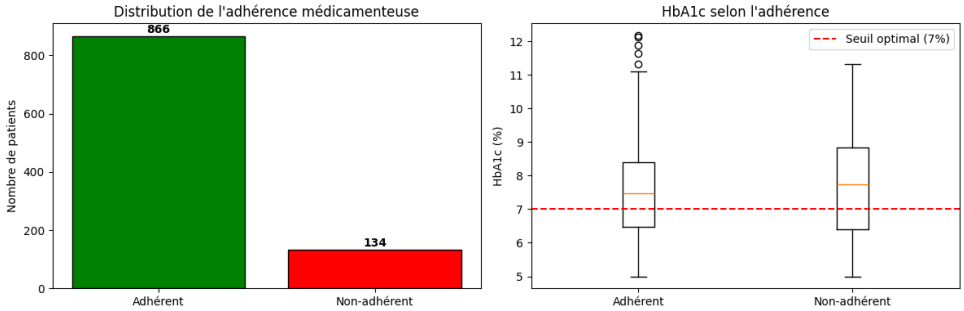

FIGURE 1 – Distribution exploratoire des données

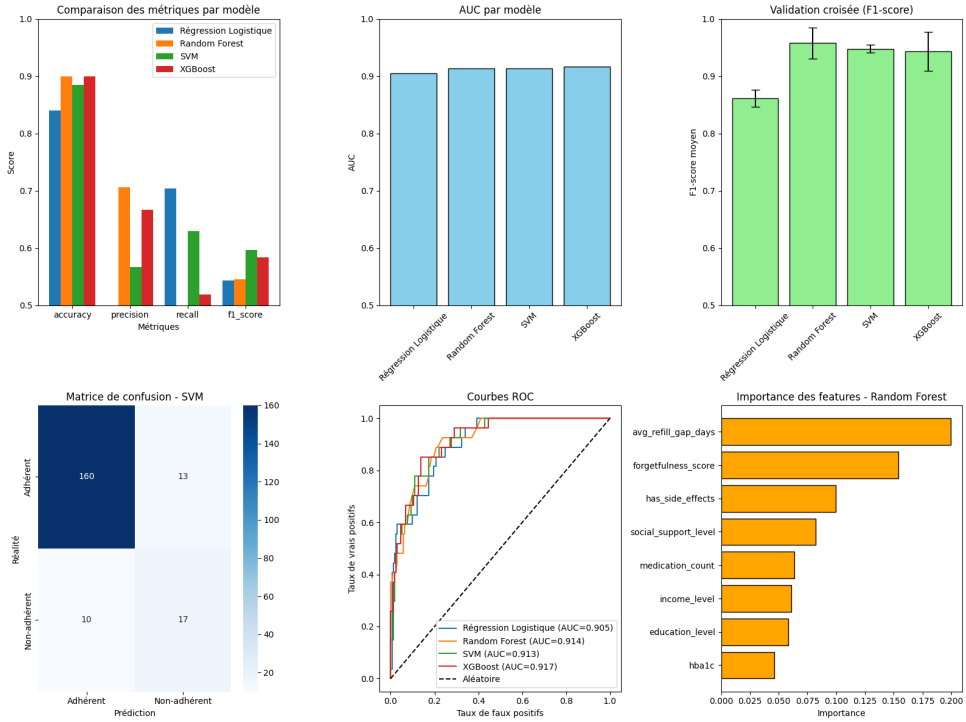

FIGURE 2 – Comparaison des performances des modèles

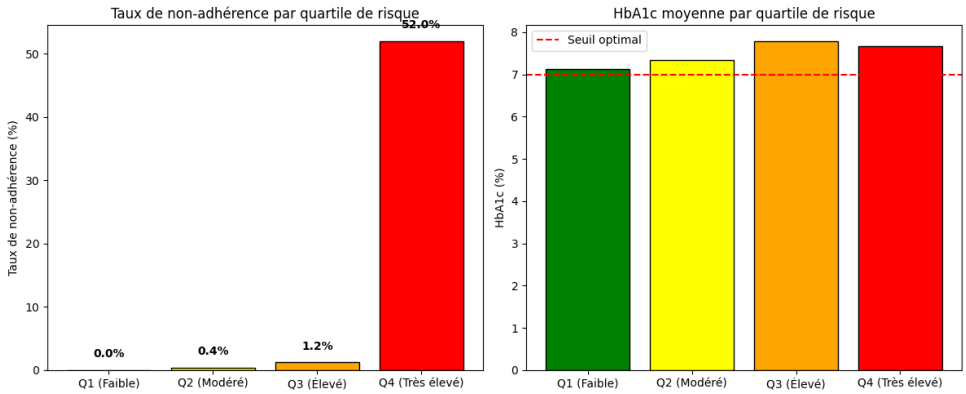

FIGURE 3 – Analyse des quartiles de risque

5 Discussion

5.1 Interprétation des résultats

Nos résultats démontrent que les modèles de machine learning, en particulier SVM, sont capables de prédire efficacement la non-adhérence au traitement chez les patients diabétiques. Le taux de reclassement observé (identification d'un groupe à 52% de risque) est cliniquement significatif.

L'identification d'un quartile "très haut risque" avec 52% de non-adhérence permet de cibler précisément les interventions éducatives et de suivi.

5.2 Comparaison avec la littérature

Nos résultats sont cohérents avec les études récentes :
— Kassaw et al. (2025) ont obtenu des AUC > 0.99 avec SVM
— Zhang & Qu (2025) ont rapporté des AUC de 0.92-0.98 avec Random Forest

5.3 Limites de l'étude

Limites méthodologiques :
— Données simulées (non réelles)
— Population limitée à 1000 patients
— Absence de validation clinique par des experts médicaux
Limites techniques :
— Dataset non représentatif de la population tunisienne
— Variables limitées (8 caractéristiques médicales)

5.4 Perspectives d'amélioration

1. Validation sur des données hospitalières réelles tunisiennes
2. Intégration de données longitudinales (suivi dans le temps)
3. Ajout de variables socio-économiques et comportementales
4. Déploiement d'un prototype pour test en conditions réelles

6 Conclusion

6.1 Contributions principales

Ce projet a démontré la faisabilité d'une prédiction précoce de la non-adhérence au traitement chez les patients diabétiques de type 2.
Principaux résultats :
— Le modèle SVM atteint un F1-Score de 0.596 et une AUC de 0.913
— L'analyse par quartiles identifie un groupe de patients avec **52% de risque de non-adhérence**
— Les patients à haut risque présentent une HbA1c moyenne de 7.7%, dépassant le seuil recommandé

6.2 Réponse à la problématique

Notre recherche répond à la problématique initiale :
— **Problème** : Les méthodes traditionnelles ne permettent pas d'identifier précocement les patients à risque de non-adhérence
— **Solution** : Un modèle SVM qui classe les patients par niveau de risque
— **Résultat** : Un outil d'aide à la décision permettant de cibler les interventions éducatives

6.3 Perspectives

Ce travail ouvre plusieurs perspectives :
— Déploiement dans un environnement clinique réel
— Extension à d'autres pathologies chroniques (hypertension, asthme)
— Développement d'une application mobile pour les patients

Annexes

Annexe A : Code source

Le code complet du projet est disponible sur GitHub : https://github.com/JouiniMaroua/MiniProjet-ML-

Annexe B : Répartition du travail

— Maroua Jouini : Rédaction du rapport, implémentation des modèles, analyse des résultats

Références

1. Kassaw, E. A., Sendekie, A. K., Enyew, B. M., & Abate, B. B. (2025). Machine learning applications to classify and monitor medication adherence in patients with type 2 diabetes in Ethiopia. *Frontiers in Endocrinology*, 16, 1486350.
2. Zhang, J., & Qu, J. Z. (2025). Assessment of Medication Adherence in Patients : Development and Validation of a Machine Learning Model. *medRxiv*, 2025.09.14.25335382.
3. World Health Organization. (2003). *Adherence to long-term therapies : evidence for action*. WHO Press.
4. Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765-4774.
5. Lundberg, S. M., Erion, G., Chen, H., et al. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56-67.